

# Recomendação Musical Em Tempo Real: Algoritmo Contextualizado Para Personalização De Listas De Reprodução

Lécio Oliveira Gonçalves de Assis  
Universidade Federal de São Paulo  
Instituto de Ciência e Tecnologia  
São José dos Campos, São Paulo 12247-014  
Email: lecio.assis@unifesp.br

**Resumo**—Este documento apresenta a formalização do projeto de um algoritmo contextualizado para personalização de listas de reprodução, com o objetivo de proporcionar recomendações musicais mais precisas e envolventes para os usuários do Spotify. O projeto visa romper com a abordagem atual de aleatoriedade aparente e criar uma nova forma de ordenação de músicas, levando em consideração critérios como histórico de reprodução, músicas recentemente ouvidas, contexto audiovisual e popularidade. A implementação será feita em Python, utilizando a API do Spotify e bibliotecas de inteligência artificial.

**Palavras-chave**—Sistemas de Recomendação Musical, Algoritmo Contextualizado, Personalização de Listas de Reprodução, Plataformas de Streaming, Regras de Associação, Mineração de Padrões Sequenciais, Contexto Audiovisual, Controle de Reprodução, Qualidade das Recomendações, Filtragem Colaborativa, Filtragem Baseada em Conteúdo.

## I. INTRODUÇÃO

A música desempenha um papel fundamental na vida das pessoas e plataformas de streaming de música, como o Spotify, têm ganhado cada vez mais popularidade. No entanto, muitos usuários enfrentam problemas ao usar a funcionalidade de reprodução aleatória, pois o algoritmo subjacente não oferece uma experiência verdadeiramente aleatória. Em vez disso, o algoritmo tende a espalhar músicas do mesmo artista ou álbum ao longo da playlist, resultando em repetição constante e falta de diversidade musical. Outro problema comumente reportado está nas recomendações. Boa parte dos algoritmos são baseados em popularidade e não trazem novidades no geral ou falham em ser relevantes para aqueles que apreciam músicas fora do mainstream. Isso leva a uma experiência decepcionante para todos que desejam descobrir novas músicas e desfrutar de uma playlist variada.

## II. FUNDAMENTOS

### A. Recomendação de Música

A recomendação de música é um campo de estudo que visa fornecer aos usuários sugestões personalizadas de músicas com base em suas preferências e características musicais. Existem diferentes abordagens para a recomendação de música, sendo as mais comuns a filtragem colaborativa e a filtragem baseada em conteúdo.

A filtragem colaborativa utiliza o comportamento passado do usuário e de outros usuários para identificar padrões e sugerir músicas com base em interesses semelhantes. A filtragem baseada em conteúdo analisa as características musicais das faixas, como gênero, artista, ritmo, melodia e harmonia, para fazer recomendações com base em similaridade.

### B. Análise de Dados Musicais

A análise de dados musicais é essencial para compreender e extrair informações relevantes das músicas. Neste projeto, utilizaremos a API do Spotify como fonte principal de informações e análise das faixas musicais. A API do Spotify fornece dados como título, artista, álbum, gênero, popularidade e características musicais, como ritmo, energia e valência. Essas informações serão utilizadas para identificar padrões, similaridades e preferências dos usuários, sem a necessidade de ferramentas adicionais de análise de áudio.

### C. Aprendizado de Máquina (Filtragem Colaborativa, Agrupamento e Regras de Associação)

O aprendizado de máquina desempenha um papel fundamental na construção de modelos de recomendação. Um método comum é a filtragem colaborativa, que utiliza algoritmos de aprendizado de máquina para identificar padrões e relações entre os usuários e as músicas. Essa abordagem busca encontrar semelhanças entre os usuários com base em seus históricos de preferências e recomendar músicas com base nas preferências de usuários semelhantes.

Algoritmos de agrupamento são técnicas utilizadas para identificar grupos de usuários com preferências semelhantes e itens (músicas) com características similares. Esses algoritmos analisam os dados coletados, como características musicais ou histórico de preferências dos usuários, e os agrupam com base em sua similaridade. Essa abordagem permite criar segmentos de usuários com interesses musicais parecidos, o que é valioso para personalizar as recomendações e oferecer sugestões relevantes aos usuários.

Por sua vez, as regras de associação são utilizadas para descobrir padrões de comportamento e preferências dos usuários. Essas regras identificam associações frequentes entre itens com

base nos dados observados. Por exemplo, se muitos usuários que gostam de um determinado gênero musical também costumam ouvir um artista específico, essa associação pode ser capturada por uma regra de associação. Essas regras fornecem insights valiosos sobre as preferências dos usuários e podem ser usadas para gerar recomendações mais precisas.

#### D. PrefixSpan para Sequential Pattern Mining

O *Sequential Pattern Mining* é uma área de pesquisa importante em mineração de dados, com aplicações em diversas áreas, incluindo análise de sequências temporais. Neste contexto, o algoritmo PrefixSpan se destaca como uma abordagem eficiente para a descoberta de padrões sequenciais em grandes conjuntos de dados. Este algoritmo utiliza a técnica de prefixo-projeção para encontrar padrões frequentes em sequências, levando em consideração a ordem e a estrutura temporal dos eventos. O PrefixSpan se demonstrou mais adequado, com suas vantagens e limitações, em nosso projeto para identificar padrões sequenciais relevantes nos dados de interações dos usuários com as músicas.

#### E. Redes Neurais

As redes neurais têm desempenhado um papel crucial no campo da visão computacional e análise de imagens. No contexto do nosso projeto, investigamos a utilidade das redes neurais na classificação de sentimentos associados a imagens. Através do treinamento de uma rede neural profunda em um conjunto de dados anotados, em próximos passos será desenvolvido um modelo capaz de reconhecer e classificar diferentes sentimentos expressos em imagens. Serão exploradas diferentes arquiteturas e técnicas de treinamento, levando em consideração a representação e extração de características relevantes para a classificação de sentimentos.

#### F. Processamento de Linguagem Natural (NLP)

O processamento de linguagem natural (NLP) é relevante para a análise de letras de músicas e textos relacionados. Técnicas de NLP podem ser aplicadas para extrair tópicos, detectar sentimentos e gerar representações textuais que enriqueçam o perfil do usuário e melhorem a precisão das recomendações.

O uso de NLP ainda está em aberto por permitir considerar não apenas as características musicais, mas também as preferências e interesses expressos pelos usuários em texto e levar em consideração as letras das músicas.

#### G. Bibliotecas e Tecnologias

O projeto faz uso de várias bibliotecas e tecnologias para implementar as funcionalidades propostas. Além da API do Spotify, que fornece acesso aos dados musicais, são utilizadas as seguintes ferramentas:

- Pandas [1]: uma biblioteca de Python para processamento distribuído de dados, que permite lidar com dados de forma rápida.
- SPMF-py [2]: um *wrapper* em Python para a avançada biblioteca open source de mineração de dados para Java, SPMF [3].

- Mlxtend [4]: é uma biblioteca em python com ferramentas úteis para tarefas de ciência de dados diárias. Seu nome vem de *Machine Learning Extensions*
- PyAudioAnalysis [5]: uma biblioteca em Python para análise de áudio, que possibilita a extração de características musicais relevantes.
- ImageAI [6]: uma biblioteca em Python para análise de dados de vídeo, que permite identificar objetos, reconhecer padrões e analisar conteúdo visual.

Essas tecnologias e bibliotecas são essenciais para implementar as funcionalidades do sistema de recomendação de música proposto, permitindo o processamento e a análise eficiente dos dados musicais e de vídeo, a construção e treinamento dos modelos de recomendação. Ao longo do projeto é provável a utilização de ferramentas alternativas, dependendo do direcionamento que as explorações tomarem.

### III. TRABALHOS RELACIONADOS

Visando facilitar a abordagem aos diversos trabalhos sobre sistemas de recomendação, a literatura será dividida em dois grupos. O primeiro grupo consiste em trabalhos que abordam conceitos básicos, soluções estabelecidas, problemas, desafios e o contexto histórico dos sistemas de recomendação. O segundo grupo abrange trabalhos que apresentam possíveis soluções, novos desafios, uma evolução em relação a modelos anteriores e análises desses modelos. O projeto atual se enquadra na categoria de literatura experimental, pois busca apresentar uma nova abordagem e soluções para desafios existentes. Os trabalhos citados a seguir fornecem uma base sólida de conhecimento teórico e exploram soluções inovadoras no campo de sistemas de recomendação de músicas.

#### A. Literatura Conceitual

[7] discute os tipos de sistemas de recomendação, como "lean-in" e "lean-back", e apresenta os desafios associados a esses conceitos.

[8] explora diferentes modelos de recomendação, incluindo modelos baseados em contexto e emoção, destacando os potenciais problemas e desafios dessas abordagens.

[9] trata especificamente do quão injusto é o viés de popularidade no contexto dos sistemas de recomendação.

[10] aborda a playlist adaptativa e os critérios de qualidade que podem ser considerados nesse tipo de recomendação.

[11] discute métodos de recomendação, como filtragem colaborativa, filtragem baseada em conteúdo, filtragem híbrida e outros, fornecendo uma visão geral dos conceitos por trás dessas abordagens.

[12] destaca os maiores desafios enfrentados pelos sistemas de recomendação, levando em consideração as limitações e questões em aberto na área.

[13] apresenta conceitos relevantes no contexto de sistemas de recomendação.

#### B. Literatura Experimental

[14] propõe um modelo de individualização utilizando big data como fonte de informação.

[15] propõe uma abordagem híbrida que busca trazer diversidade e evitar o problema do "cold-start" na recomendação de músicas.

[16] apresenta vários problemas identificados em uma abordagem anterior e propõe um modelo aprimorado para superar essas limitações.

[17] explora a utilização de modelos de Redes Neurais Convolucionais para a classificação da emoção de imagens.

[18] propõe uma nova rede de aprendizado profundo de representações profundas de múltiplos níveis para classificação de emoções em imagens (MldrNet).

#### IV. OBJETIVO

O objetivo principal deste artigo é apresentar o desenvolvimento de um modelo de recomendação musical personalizado, baseado em padrões de reprodução do usuário, utilizando algoritmos de *Sequential Pattern Mining*. Além disso, exploramos a possibilidade de classificar a emoção transmitida por imagens e relacionar esses dados com as características de áudio das músicas, visando criar um modelo de sinestesia. Por fim, buscamos investigar a experiência do usuário e desenvolver uma interface interativa para a interação com o sistema de recomendação.

O cerne do nosso trabalho consiste na criação de um modelo de recomendação musical que se adapte aos padrões individuais de reprodução dos usuários. Utilizamos algoritmos de *Sequential Pattern Mining* para identificar sequências de reprodução relevantes e descobrir padrões de preferências musicais. A partir desses padrões, o modelo é capaz de realizar recomendações personalizadas, equilibrando familiaridade e descoberta, com o objetivo de proporcionar uma experiência musical mais envolvente e satisfatória. Além de algoritmos de Mineração de Padrões Sequenciais foram exploradas outras opções, como Regras de Associação, mas os resultados não se mostraram adequados.

Adicionalmente, exploramos a classificação da emoção transmitida por imagens para enriquecer o processo de recomendação musical. Investigamos técnicas de aprendizado de máquina para desenvolver um modelo capaz de reconhecer e classificar sentimentos expressos em imagens. Esses dados de classificação são então correlacionados com as características de áudio das músicas para estabelecer conexões sinestésicas entre estímulos visuais e auditivos.

Por fim, reconhecendo a importância da experiência do usuário, também nos propomos a desenvolver uma interface interativa para a interação com o sistema de recomendação. Embora não estejamos planejando a distribuição do software, devido a questões regulamentares, estamos comprometidos em projetar uma interface intuitiva e amigável, com o objetivo de proporcionar aos usuários uma experiência agradável e facilitar a descoberta musical personalizada.

#### V. METODOLOGIA EXPERIMENTAL

##### A. Base de Dados

1) *Histórico Ampliado de Streaming*: Esses dados são solicitados diretamente na sessão de privacidade do Spotify.

Possui o histórico de streaming anual do usuário. Possui vários detalhes sobre cada streaming:

- Data e hora, no formato UTC (Tempo Universal Coordenado), do fim do último streaming.
- Seu nome de usuário do Spotify.
- Plataforma usada para tocar a faixa (por exemplo, Android OS, Google Chromecast).
- Por quantos milésimos de segundos você ouviu a faixa.
- Código do país onde a faixa foi ouvida.
- Endereço IP usado para tocar a faixa.
- Agente do usuário utilizado para tocar a faixa (por exemplo, um navegador, como o Mozilla Firefox ou o Safari).
- Nome da faixa.
- Nome do artista, banda ou podcast.
- Nome do álbum da faixa.
- Uma URI de faixa do Spotify, que identifica apenas essa música.
- Nome do episódio do podcast.
- Nome do programa do podcast.
- Uma URI de episódio do Spotify, que identifica apenas esse episódio do podcast.
- Por que a faixa começou (por exemplo, a faixa anterior terminou ou você escolheu na playlist).
- Por que a faixa terminou (por exemplo, a faixa tocou até o fim ou você clicou em "Avançar").
- Se a ordem aleatória foi usada quando a faixa estava tocando.
- Se o usuário pulou para a próxima música.
- Se a faixa foi ouvida no modo offline.
- Marcação de tempo de quando e se o modo offline foi usado.
- Se a faixa foi ouvida em uma sessão particular. [19]

Estes dados foram solicitados por alguns usuários selecionados, com um período de até 30 dias para retorno a partir da solicitação. Mais amostras serão adquiridas, de forma a ampliar estas amostras para treinamento.

Durante a execução do projeto, foi constatado que essa lista de informações estava desatualizada, deixando muitas análises interessantes impossíveis. Os dados referentes ao histórico ampliado encontrados após a requisição foram apenas o tempo de reprodução da faixa, o horário em que a faixa terminou sua reprodução (interrompida ou não), nome da música e nome do artista (apenas um dos artistas).

2) *Análise de Áudio da Faixa*: "Obtenha uma análise de áudio de baixo nível para uma faixa no catálogo do Spotify. A análise de áudio descreve a estrutura da faixa e o conteúdo musical, incluindo ritmo, altura e timbre." [20] Cada faixa possui 6 sessões de informações diferentes relacionadas ao áudio, a mais relevante é chamada "track". Se trata de uma análise relativamente menos técnica que as outras e fornecer, de forma simplificada, os mesmos dados. Portanto será a única a ser utilizada em qualquer situação. Estas análises podem ser obtidas em forma de requisições na API do Spotify, porém como forma de simplificar o processo e poder analisar o conjunto como um todo, será usada uma amostra [21],

referentes a músicas lançadas entre 1921 e 2021. Ela possui aproximadamente 600 mil músicas, sendo uma representação de 0.5% de todas as faixas disponíveis na plataforma. Também serão feitas requisições de forma inteligente, de acordo com os conhecimentos adquiridos na amostra e através da requisição de outros dados, como Top Artistas, Top Músicas e Itens favoritos.

3) *Músicas Tocadas Recentemente*: Neste endpoint será obtido o histórico recente de streaming do usuário, limitado a 50 itens. Seu uso principal será na aplicação do modelo e não no treinamento ou teste. Poderá também ser a fonte de um histórico ampliado artificial, armazenando o histórico recente ao longo do tempo, tornando o modelo mais específico para o usuário.

4) *Recomendações*: Este endpoint da API será usado como forma de validação das recomendações obtidas com o modelo. Aqui temos os mesmos parâmetros de tolerância relativos aos encontrados na Análise de Áudio da Faixa e Artistas, Gêneros e Músicas de origem.

### *B. Coleta de Dados*

A coleta de dados será realizada por meio da API de desenvolvimento do Spotify. A API fornecerá acesso a informações relevantes relacionadas ao usuário, como histórico de reprodução, e relacionadas às músicas, como a análise aprofundada do áudio, detalhes sobre o álbum e o artista e índices de popularidade. Esses dados serão essenciais para alimentar o algoritmo de recomendação e fornecer insights sobre as preferências musicais dos usuários.

### *C. Pré-processamento de Dados*

Os dados coletados da API do Spotify passarão por um processo de pré-processamento para remover informações irrelevantes, tratar dados ausentes e normalizar formatos. Serão aplicadas técnicas de limpeza de dados, como remoção de duplicatas, tratamento de valores nulos e padronização de atributos, garantindo que os dados sejam consistentes e adequados para uso no algoritmo de recomendação. Devido à grande quantidade de dados existentes, essa etapa será fundamental para que os objetivos sejam alcançados, utilizando o PySpark como ferramenta para lidar com grandes volumes de informações de forma eficiente.

### *D. Desenvolvimento da Recomendação*

O algoritmo de recomendação será desenvolvido em Python, utilizando bibliotecas e frameworks adequados, como scikit-learn e TensorFlow. Serão exploradas técnicas de aprendizado de máquina, como filtragem colaborativa, agrupamento, busca de informação, regras de associação e processamento de linguagem natural, para identificar padrões nos dados e realizar recomendações personalizadas com base nos critérios estabelecidos. O algoritmo levará em consideração o histórico de músicas ouvidas, músicas recentemente ouvidas, contexto audiovisual e popularidade para criar listas de reprodução mais coesas e atraentes para os usuários.

### *E. Integração do Contexto Audiovisual*

Uma inovação deste projeto é a incorporação do contexto audiovisual externo ao algoritmo. Por meio da captura de imagens e vídeos de um dispositivo, o algoritmo terá a capacidade de "ver" e "ouvir", permitindo a distinção de elementos presentes no ambiente. Essa percepção audiovisual adiciona uma camada adicional de informações ao processo de seleção de músicas, melhorando ainda mais a qualidade das recomendações musicais. Para a execução deste processo serão exploradas bibliotecas para análise de áudio, como PyAudioAnalysis, e bibliotecas para interpretação de imagens, como ImageAI, sendo que ambas já implementam diferentes modelos de inteligência artificial.

### *F. Interface de Usuário*

Será desenvolvida uma interface de usuário que permitirá aos usuários fazer login com sua conta do Spotify e conceder as permissões necessárias para uma experiência personalizada. A interface também possibilitará que os usuários interajam com a lista de reprodução recomendada, fornecendo feedback sobre as músicas sugeridas e permitindo alterações na lista de reprodução de acordo com suas preferências. O desenvolvimento de uma interface gráfica não possui prioridade dentre os objetivos, ao longo do projeto decisões serão tomadas quando a sua implementação, sendo essencial apenas uma interface de linha de comando.

### *G. Descrição do Pipeline*

Essa subseção se aprofundará na descrição do Pipeline encontrado na figura 1. Devido a limitações da API, a aquisição dos dados foi feita de forma bem esparsa ao longo do projeto, com dezenas de solicitações diferentes em uma única análise. Os principais acessos aos endpoints e outras formas de requisição de dados serão detalhados nessa seção.

Para a execução do projeto, são feitas três principais solicitações de dados. O histórico a longo prazo, necessário para a mineração dos padrões sequenciais. As informações sobre a reprodução atual, que contém detalhes sobre a faixa e o contexto. O carregamento do contexto áudio visual se trata de qualquer que seja a forma de contextualização, a camera de um celular, de um óculos inteligente, ou imagens e vídeos selecionados para uma contextualização específica.

Ao carregar o histórico a longo prazo, após solicitação de tal para a empresa, os dados são formatados da maneira adequada. Esse histórico não possui ID das faixas, então é feita uma busca reversa a partir do nome da faixa e dos artistas, o que pode resultar em algumas falhas devido ao comprimento dos nomes e caracteres não suportados. A partir dos IDs no histórico são minerados Padrões de Sequência, utilizando do algoritmo de PrefixSpan, por se mostrar o mais correto e eficiente para a aplicação por enquanto.

A partir das informações da reprodução atual, são obtidos dados das faixas relevantes para o contexto, seja do álbum, playlist, artista, músicas salvas pelo usuário ou nenhum desses (no caso de reprodução diretamente da barra de pesquisa). As faixas relevantes para o contexto são importantes para fornecer

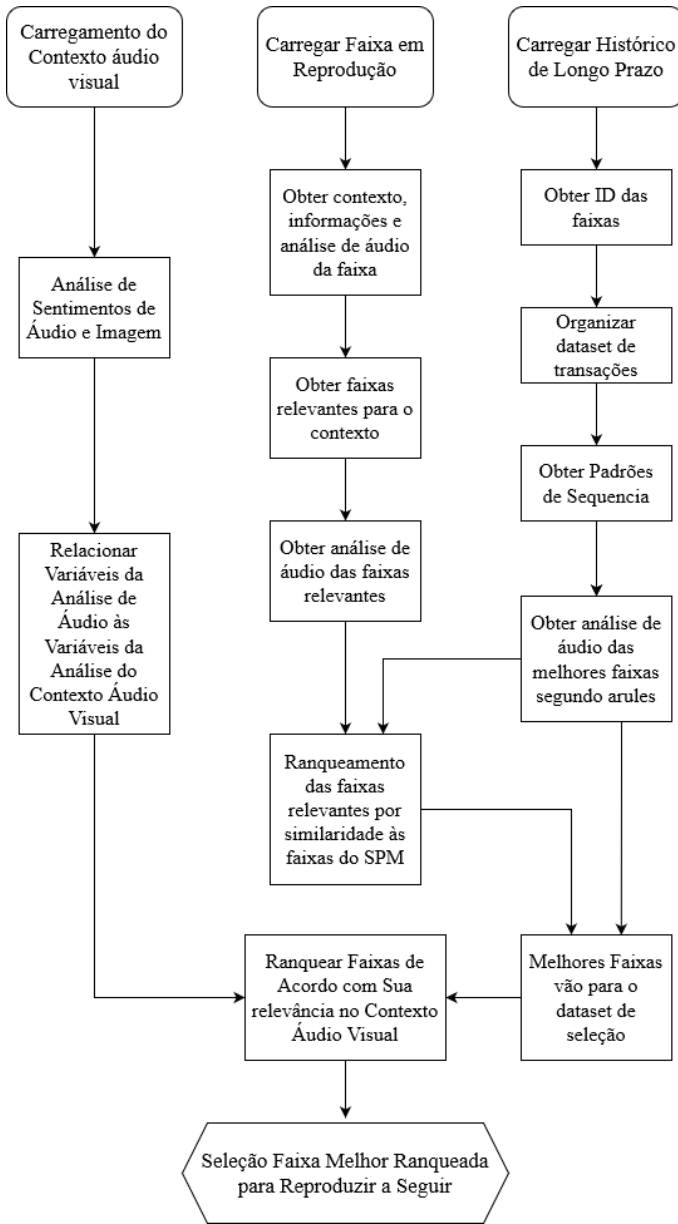


Figura 1. Diagrama de Blocos do Pipeline Experimental. Fonte: Autor

músicas diferentes das que são encontradas no álbum, playlist ou qualquer outro contexto de reprodução, porém que ainda façam sentido para o usuário. Utilizando das características das músicas encontradas nos Padrões de Sequência, é calculada uma nota de similaridade para as músicas deste passo.

O contexto áudio visual é adquirido através de um vídeo (imagens e som) e, por meio de um modelo ainda a ser discutido, é feita uma análise de classificação de emoção, que é então relacionada aos atributos das músicas (*acousticness, danceability, energy, instrumentalness, key, liveness, loudness, mode, speechiness, tempo, time\_signature, valence*). Essa classificação é então comparada com as músicas obtidas no contexto e na mineração de padrões e uma nota é dada para cada uma.

A música a ser tocada a seguir é aquela com a melhor média ponderada de desempenho. Sendo os pesos para cada um dos passos baseados na confiança de cada análise.

## VI. RESULTADOS

O desenvolvimento do projeto enfrentou várias limitações, das quais muitas foram superadas ao longo do caminho para alcançar os objetivos propostos. Inicialmente, nos deparamos com a indisponibilidade de dados prontos para serem utilizados na concepção de um modelo de inteligência artificial. De fato, a empresa provedora desencorajava o uso desses dados. Diante dessa situação, adotamos uma abordagem de redução das requisições à API, selecionando apenas as músicas mais relevantes para o contexto e em conformidade com as regras de associação estabelecidas pelo histórico de reprodução.

Em um segundo momento, constatamos a escassez de estudos e modelos que propõem a correlação entre áudios e imagens, assim como a análise dos sentimentos humanos associados a esses elementos. Embora a sinestesia, que era um ponto central e esperado do projeto, não tenha sido concluída dentro do prazo proposto.

Como resultado final, obtivemos um projeto que não se deixou abater pela falta de acesso adequado aos dados, demonstrando resiliência e adaptabilidade. Esse projeto servirá como uma base sólida para o desenvolvimento de um trabalho mais abrangente, que reunirá estudos adicionais para correlacionar emoções, áudio e vídeo em um modelo mais avançado.

A busca pela sinestesia, ou seja, a exploração da correlação entre os sentimentos transmitidos por imagens e as características de áudio das músicas, é uma etapa que está planejada para as próximas fases do projeto. Pretendemos explorar modelos de classificação de sentimentos de imagens, a fim de enriquecer ainda mais a personalização das recomendações musicais.

Em conclusão, o projeto de desenvolvimento de um algoritmo contextualizado para personalização de listas de reprodução no Spotify representa uma abordagem inovadora. Diante da constatação de que os algoritmos existentes não atendiam plenamente às necessidades do projeto, foi necessário empreender esforços no desenvolvimento de um novo algoritmo. Essa inovação exigiu tempo adicional para aprimoramento e validação, mas acreditamos que os resultados alcançados até o momento representam um avanço significativo.

Como uma solução pioneira nesse campo, reconhecemos que ainda há espaço para aperfeiçoamento e expansão do projeto. A correlação entre emoções, áudio e vídeo apresenta um potencial promissor para melhorar a experiência de recomendação musical personalizada. Portanto, é fundamental continuar explorando e aprofundando as relações sinestésicas entre diferentes formas de estímulo sensorial.

No geral, o projeto demonstrou que, mesmo diante de desafios e limitações, é possível encontrar soluções criativas e promissoras para atender às demandas específicas de recomendação musical personalizada. A busca contínua por inovação e aprimoramento nesse campo é fundamental para

proporcionar aos usuários uma experiência musical mais envolvente e satisfatória.

## REFERÊNCIAS

- [1] Pandas. Disponível em: <https://pandas.pydata.org/>.
- [2] SPMF-py. Disponível em: <https://github.com/LoLei/spmf-py>.
- [3] SPMF. Disponível em: <http://www.philippe-fournier-viger.com/spmf/>.
- [4] Mlxtend (machine learning extensions). Disponível em: <https://github.com/rasbt/mlxtend>
- [5] pyAudioAnalysis. Disponível em: <https://github.com/tyiannak/pyAudioAnalysis>.
- [6] ImageAI. Disponível em: <https://github.com/OlafenwaMoses/ImageAI>.
- [7] Schedl, M., Knees, P., McFee, B. & Bogdanov, D. Music recommendation systems: Techniques, use cases, and challenges. *Recommender Systems Handbook*. pp. 927-971 (2021)
- [8] Song, Y., Dixon, S. & Pearce, M. A survey of music recommendation systems and future perspectives. *9th International Symposium On Computer Music Modeling And Retrieval*. **4** pp. 395-410 (2012)
- [9] Kowald, D., Schedl, M. & Lex, E. The unfairness of popularity bias in music recommendation: A reproducibility study. *Advances In Information Retrieval: 42nd European Conference On IR Research, ECIR 2020, Lisbon, Portugal, April 14–17, 2020, Proceedings, Part II* **42**. pp. 35-42 (2020)
- [10] Jannach, D., Kamehkhosh, I. & Bonnin, G. Music Recommendations. (2018)
- [11] Qin, Y. A historical survey of music recommendation systems: Towards evaluation. (McGill University (Canada), 2013)
- [12] Schedl, M., Zamani, H., Chen, C., Deldjoo, Y. & Elahi, M. Current challenges and visions in music recommender systems research. *International Journal Of Multimedia Information Retrieval*. **7** pp. 95-116 (2018)
- [13] Zhang, Q., Lu, J. & Jin, Y. Artificial intelligence in recommender systems. *Complex & Intelligent Systems*. **7** pp. 439-457 (2021)
- [14] Sun, P. Music Individualization Recommendation System Based on Big Data Analysis. *Computational Intelligence And Neuroscience*. **2022** (2022)
- [15] Kaufman, J. A Hybrid Approach to Music Recommendation: Exploiting Collaborative Music Tags and Acoustic Features. (2014)
- [16] Hu, Y. A model-based music recommendation system for individual users and implicit user groups. (University of Miami, 2014)
- [17] Chen, M., Zhang, L. & Allebach, J. Learning deep features for image emotion classification. *2015 IEEE International Conference On Image Processing (ICIP)*. pp. 4491-4495 (2015)
- [18] Rao, T., Li, X. & Xu, M. Learning multi-level deep representations for image emotion classification. *Neural Processing Letters*. **51** pp. 2043-2061 (2020)
- [19] Como Interpretar Meus Dados. Disponível em <https://support.spotify.com/br-pt/article/understanding-my-data/>
- [20] Análise de Áudio da Faixa. Disponível em <https://developer.spotify.com/documentation/web-api/reference/get-audio-analysis>
- [21] Spotify Dataset 1921-2020, 600k+ Tracks. Disponível em [https://www.kaggle.com/datasets/yamaerenay/spotify-dataset-19212020-600k-tracks?resource=download&select=dict\\_artists.json](https://www.kaggle.com/datasets/yamaerenay/spotify-dataset-19212020-600k-tracks?resource=download&select=dict_artists.json)